

クラウドLLMとローカルLLMをプライバシー境界で切り分けるLLM呼び出しフレームワーク詳細比較レポート

エグゼクティブサマリ

本調査で挙げた候補は、実態としては同じ種類の「LLMオーケストレーション基盤」ではありません。大きく分けると、データ境界と参照整合性を扱うレジストリ型の **NBAccess / SourceVault**、実運用のゲートウェイやエージェントのフックで再検査するルータ型の **ClawXRouter / EdgeClaw** と **vLLM Semantic Router**、プライバシー-性能トレードオフを研究する推論方式の **PRISM / Privacy-R1 / PrivacyRestore**、ローカル匿名化やローカルRAGで外部送信をそもそも減らす方式の **AgentStealth / SEAL / EvidenceBot / SecureLLM**、そして評価・匿名化ツール群の **ConfAlde / PrivacyLens / IBM AI Privacy Toolkit** に分かれます。したがって、これらは排他的な代替品というより、組み合わせるべきレイヤです。 ①

「httpd のアクセス制御ファイルのように、データそのものではなく場所にだけ権限を付ける」設計に近いミス、つまりファイル移動・コピー・別経路からの参照でラベルが脱落する漏洩に対して、今回の候補の中で比較的強いのは **NBAccess / SourceVault** と **ClawXRouter / EdgeClaw** です。前者は、ファイルや値を **ObjectSpec** として正規化し、**PrivacyLevel** をデータモデルに持たせ、さらに **content hash・immutable snapshot・append-only event log・bundle** 依存関係でプロベナンスを追えるため、少なくとも管理対象に入ったデータについては「場所依存」から一歩進んでいます。後者は、**before/after** のフックでメッセージ、ツール呼び出し、ツール結果、永続化時点を再検査し、**dual-track memory / dual-track sessions** によってクラウド側履歴を常に脱機微版へ落とすため、ラベル喪失をシンク直前の再検査で吸収しやすい設計です。 ②

一方で、**PRISM / Privacy-R1 / PrivacyRestore / AgentStealth / SEAL** は、どれも論文としては優れたプライバシー保護手法ですが、公開情報の範囲では **OS レベルの Mandatory Access Control**、データバウンドな恒久ラベル、**content-hash** 追跡によるファイル移動耐性まで備えてはいません。これらは主に、送信前にどこまで匿名化・分割・摂動・局所推論するかを最適化する仕組みであり、うっかり別フォルダへ動かしたファイルがそのままクラウド経路に乗る類の事故を、単独で防ぐ設計ではありません。 ③

性能面では、公開ベンチマークが明確なのは主に **ClawXRouter / EdgeClaw / vLLM Semantic Router / PRISM / PrivacyRestore** です。**ClawXRouter** は PinchBench で **58% コスト削減** と **6.3% スコア向上** を掲げ、**EdgeClaw** は長いセッションで **85% のトークン節約** をうたいます。**vLLM Semantic Router** は MMLU-Pro で **レイテンシ 47.1% 減**、**トークン 48.5% 減**、**精度 10.24 ポイント向上** を報告し、記事レベルではインテリジェントルーティングで **90% 超のトークンコスト削減** もあり得るとされています。**PRISM** はベースライン比で **エネルギーとレイテンシを 40-50% に抑え**、**PrivacyRestore** は inference throughput を **元の 65-80% 程度維持** したと報告しています。 ④

結論を先に言うと、短期では **ClawXRouter** 型のフックベース再検査を既存のオーケストレータに入れ、中期では **NBAccess + SourceVault** 型の data-bound な **ObjectSpec / source ID / content-hash / provenance** を管理面へ導入し、長期では **OS サンドボックス + confidential inference** まで接続するのが最も実用的です。今回の候補群をそのまま一つだけ採るなら、ファイル移動やラベル喪失に最も強く寄せやすい種は **NBAccess + SourceVault**、運用中の実害を最も止めやすい種は **ClawXRouter / EdgeClaw** です。理想解は


その両方を合わせ、クラウド出口に **vLLM Semantic Router** 的なゲートウェイ再検査を重ねる三重防御です。 5

調査範囲と評価基準

本レポートは、公式ドキュメント、論文、公式 GitHub を優先し、候補ごとに **目的、アーキテクチャ、主要コンポーネント、プライバシー境界の実装、ラベル伝播、シンク再検査、ファイル移動耐性、性能影響、運用負荷** を比較しました。なお、**NBAccess / SourceVault** と **ClawXRouter / EdgeClaw / vLLM Semantic Router** は比較的「実装・公開コード」が強く、**PRISM / Privacy-R1 / PrivacyRestore / AgentStealth / SEAL / SecureLLM** は「研究プロトタイプ」の色が濃く、**ConfAlde / PrivacyLens / IBM AI Privacy Toolkit** は「評価・匿名化ツール」であるため、同一の土俵での単純比較には限界があります。 6

今回の重要な評価軸は、通常の PII マスキングより一段厳しいものです。とくに重視したのは、**ラベルがデータに結び付いているか、経路の途中ではなくシンク直前でも再検査できるか、プロベナンスと content-hash で移動・複製後も追跡できるか、ツール呼び出しや内部チャンネルも監査対象になっているか、クラウド API コスト最適化と安全性が同時に設計されているか、の五点です。**これは近年のベンチマークが、最終出力だけでなく**内部チャンネルやツール引数**における過剰開示を重大問題として捉えている流れとも整合します。**PrivacyLens** はエージェント行動の privacy norm awareness を評価し、**ToolPrivacyBench** は tool trajectory 上の need-to-know 境界を監査し、**AgentLeak** は multi-agent の内部チャンネルが出力チャンネル以上に漏れやすいと示しています。 7

以下の図は、本レポートで整理した設計レイヤです。「ラベルを持つデータ面」、「ルーティングするオーケストレーション面」、「最後に止めるシンク面」を分離してみると、各候補の守備範囲が見えやすくなります。これは各システムの公開アーキテクチャをもとにした整理です。 8



フレームワーク比較

まず俯瞰すると、**NBAccess / SourceVault** は「何が機密で、どこから来たデータか」を扱う層です。**NBAccess** は Input セルの代入文を静的解析して**依存グラフ**を作り、機密変数に直接・間接に依存するセルを検出します。さらにファイル・ディレクトリ・値を **ObjectSpec** とし、**PrivacyLevel** と **RootId / Parts / SymbolicPath / ResolutionStatus** を持つ形へ正規化します。**SourceVault** はそれを受けて、**source / snapshot / claim / bundle** を **content-addressed** かつ **append-only** に管理し、外部 LLM には **sanitized snippet のみ**を渡す不変条件を置いています。ここが、本調査の中で最も「場所」ではなく「データ+由来」に寄った設計です。 9

ClawXRouter / EdgeClaw は、現実のエージェント実行経路で事故を止める設計です。**ClawXRouter** は **S1/ S2/S3** の三段階**プライバシールーティング**を持ち、S2 は redact してクラウド転送、S3 は完全ローカルにします。**EdgeClaw** はその上で、**before_model_resolve / before_prompt_build / before_tool_call / after_tool_call / tool_result_persist / before_message_write** の各フックに割り込み、**dual-track memory / dual-track sessions** によってクラウドモデルが見える履歴とローカル履歴を分離します。これは「ファイル移動前にラベルが残っていたか」だけに依存せず、**送る直前・保存する直前にもう一度見る**とい

う実践的設計です。さらに **ClawXGovernor** がツール呼び出しの risk interception と audit を行い、**ClawXSandbox** が system-level sandboxing を提供します。 10

vLLM Semantic Router は、よりゲートウェイ寄りです。Envoy の **ext_proc** フィルタとして入り、Go / Rust ベースの分類パイプラインで **PII / jailbreak / intent / reasoning need** を見てどのモデルへ流すか決めます。公開資料では、**PII 検出はゲートウェイレベルで各 request を inspect し、検出時はモデルに送らず content-filtered response を返す設計**です。これは**モデル呼び出し前の出口警備**としては有効ですが、**ファイル由来の provenance や content-hash**まで持つわけではないため、「移動でラベルが落ちたファイル」がそのまま prompt へ混ざる問題には単独では弱いです。 11

PRISM / Privacy-R1 / PrivacyRestore は、いずれも優れた研究系ですが、性質が異なります。PRISM は **edge 側で感度 profiling と soft gating**を行い、必要時のみ **adaptive two-layer local DP**をかけて cloud に semantic sketch を作らせ、edge SLM で refinement します。Privacy-R1 は query を sentence chunk に切り、**stateful policy agent** が local / remote を chunk 単位で学習的に選びます。PrivacyRestore は client-server 形式で、client が privacy span を除去し、server 側が事前学習した **restoration vector** により情報を復元する方式です。いずれも**送信する内容の作り方は洗練**されていますが、公開資料上は**ファイル・オブジェクト単位の持続ラベルや OS フックは中心機能ではありません**。 12

AgentStealth / SEAL / EvidenceBot / SecureLLM は、「クラウドへ送らない」「局所匿名化する」「データを silo に閉じ込める」方向です。AgentStealth と SEAL はどちらも**ローカル SLM 匿名化**を強く推し、SEAL は 8B SLM が GPT-4 匿名化器に近い privacy-utility を達成したと報告し、AgentStealth は匿名化効果と utility の改善を示しています。EvidenceBot は**完全ローカル RAG**で、関連 chunk だけを使う privacy-preserving pipeline をうたい、SecureLLM は**silo ごとに別 fine-tuning**し、ユーザ credential に応じて推論時に合成することで unauthorized leakage を防ぐ方針です。ただし、これらは**オーケストレータの内部ツール経路や、ファイル移動時のラベル保持**を主眼にしたものではありません。 13

ConfAlde / PrivacyLens / IBM AI Privacy Toolkit は、単独では「境界付き LLM オーケストレータ」ではありません。ただし導入時には非常に重要です。ConfAlde は **contextual integrity** に基づく privacy reasoning ベンチマーク、PrivacyLens は privacy-sensitive seeds を vignette と agent trajectory へ展開する行動評価フレームワークです。IBM AI Privacy Toolkit は **anonymization / privacy risk assessment / model privacy compliance** のための Python ライブラリで、ランタイムの route 制御ではなく、評価・学習前処理・匿名化に向きます。IBM にはこれと別に、**user-to-agent boundary の overdisclosure**を抑える **Contextual Privacy Toolkit** も公開されていますが、こちらもやはり前段の reformulation 層です。 14

比較表

フレームワーク	位置づけ	概要と主要コンポーネント	プライバシー境界の実装	公開状況	参考 URL
NBAccess + SourceVault	データ面 + レジストリ + 実行承認	NBAccess は依存グラフ、ObjectSpec、AccessPathRef、NBAuthorize/RouteDecision。SourceVault は source/snapshot/claim/bundle、immutable snapshot、append-only event log、release gate。	PrivacyLevel、ObjectSpec、normalized path、sanitized snippet、2段階 authorization、content-hash、bundle 依存追跡。	GitHub 中心。論文より実装先行。	15
ClawXRouter / EdgeClaw	ルータ + エージェント実行フック	S1/S2/S3 privacy router、cost-aware router、dual-track memory、tool governance、sandbox。	semantic + rule dual detection、redaction、fully-local routing、tool/result/session 再検査、audit、sandbox。	OSS 実装。	16
vLLM Semantic Router	ゲートウェイ型ルータ	Envoy + ext_proc、Go/Rust classifier、PII/jailbreak/intent/reasoning detectors、semantic cache、model selection。	request-level gateway inspection、PII block、location-aware routing。	OSS + 論文/ブログ。	17
PRISM	研究系 privacy-aware cloud-edge inference	sensitivity profiling、soft gating、adaptive two-layer LDP、cloud semantic sketch、edge refinement。	entity-level sensitivity、three-mode route、local DP、semantic sketch collaboration。	論文 + コード公開案内。	18
Privacy-R1	研究系 learned dynamic delegation	semantic chunking、MiniLM embedding、lightweight Transformer policy agent、PPO。	chunk-level local/remote routing、replaceable/task-critical PII の学習的分離。	ACL 2026 論文。	19

フレームワーク	位置づけ	概要と主要コンポーネント	プライバシー境界の実装	公開状況	参考 URL
PrivacyRestore	client-server inference privacy	offline restoration vectors、client-side span removal、meta restoration vector、server-side restoration。	privacy span removal、dx-privacy、restoration vector、constant privacy budget。	ACL 2025 論文。	20
AgentStealth / SEAL	ローカル匿名化 SLM	adversarial anonymization、SFT + RL、self-refinement/distillation。	pre-send anonymization、local-only inference path、utility-aware anonymization。	arXiv + GitHub。	21
EvidenceBot	ローカル RAG	local knowledge base、customizable RAG pipeline、ground-truth evaluation。	relevant chunk only、local processing、no public-cloud dependency by default。	論文 + GitHub。	22
SecureLLM	データ silo 合成型	silos ごとの fine-tuning、credential-based inference-time composition。	data-silo segregation、verified credentials に基づく composition。	arXiv / ACL workshop / GitHub。	23
ConfAlde / PrivacyLens / IBM APT	評価・匿名化ツール	contextual privacy benchmark、agent trajectory evaluation、anonymization/risk assessment toolkit。	contextual privacy evaluation、privacy norm awareness、training-data anonymization。	論文 + OSS。	24

フレームワーク	防御策	ラベル伝播	再検査可否	OSフック可否	ファイル移動・ラベル喪失耐性	性能影響
NBAccess + SourceVault	ObjectSpec、PrivacyLevel、release gate、whitelist、契約検証、pre-scan、append-only event log。	強い。値・パス・source/snapshot に付随。	可。authorization、release gate、call validator。	公開資料上は限定的。Notebook/semantic API 側。	比較的強い。 content-hash・immutable snapshot・bundle provenance がある。ただし管理外コピーには限界。	公開ベンチマークなし。 推定では deterministic 判定中心で軽量、OCR/ingest は別コスト。
ClawXRouter / EdgeClaw	S1/S2/S3、tool/result/session hook、dual-track memory、audit、sandbox。	中～強。経路ごとの再分類で補完。	強い。before/after 各 hook で再検査。	可。ClawXSandbox が system-level sandboxing。	強い。送信直前・永続化直前の再検査でラベル脱落を吸収しやすい。	58% cost savings、6.3% higher score。長セッションでは 85% token saving。 26
vLLM Semantic Router	Envoy gateway、PII/jailbreak detector、semantic routing。	弱い。request-level classification 中心。	可。gateway で every request inspect。	不可。公開資料は gateway 層。	限定的。prompt 化後の PII は止められるが provenance は持たない。	latency -47.1%、tokens -48.5%、accuracy +10.24pp。 28
PRISM	edge profiling、soft gating、two-layer LDP、semantic sketch。	中。entity risk を route に反映。	部分的。collab path で再処理。	不可。	弱い。prompt 内容の保護であり、ファイル由来追跡はない。	energy/latency 40–50% of baseline。 18
Privacy-R1	chunk routing、RL policy、local/remote balance。	中。chunk 単位。	部分的。chunk routing 再決定。	不可。	弱い。データオブジェクト追跡ではない。	レイテンシ/コストの公表は限定的。 local + policy 推論分の追加はあるとみるべき。 29

フレームワーク	防御策	ラベル伝播	再検査可否	OSフック可否	ファイル移動・ラベル喪失耐性	性能影響
PrivacyRestore	span removal + restoration vector。	弱い。span 種別中心。	部分的。client/server で二段。	不可。	弱い。ファイル move 耐性は設計範囲外。	inference throughput 65-80% 、slight latency。 30
AgentStealth / SEAL	local anonymizer、utility-preserving rewrite。	弱い。匿名化後テキスト中心。	部分的。self-refinement はあるが sink gate ではない。	不可。	弱い。ラベル持続ではなく匿名化頼り。	cloud API 不要化で通信/APIコストを削減。公開 latency 数値は限定的。 32
EvidenceBot	local RAG、bounded context。	弱い。retrieval context 単位。	限定的。retrieval 時に relevant chunk のみ。	不可。	中。そもそも local-only なら egress は減るが、label persistence はない。	API コストは local なら極小。公表 benchmark は限定的。
SecureLLM	siloe fine-tunes + credential composition。	中〜強。silo 権限が中心。	部分的。inference-time composition で制限。	不可。	中。silo 境界には強いが file-level provenance ではない。	公表 serving benchmark は限定的。モデル運用は重い。
ConfAlde / PrivacyLens / IBM APT	benchmark、anonymization、risk assessment。	該当なし	評価用途として可	不可	防御ではなく評価・前処理。	本番 latency 議論の対象外。

ラベル喪失とファイル移動に対する耐性

この論点で最も重要なのは、「**権限がファイルパスに付いている**」のか、「**データオブジェクトや由来に付いている**」のかです。今回の候補の中で、**明示的にデータ寄りへ寄せているのは NBAccess / SourceVault** です。NBAccess はファイルや値を **ObjectSpec** 化して **PrivacyLevel** を持たせ、さらに **NBNormalizePath** で symbolic path と resolution status を保持します。SourceVault は ingest した source を **raw/by-hash** に置き、**source record / snapshot record / bundle dependency** を immutable / append-only に管理します。つまり、少なくとも SourceVault 管理下に入ったオブジェクトは、**フォルダ依存より content-addressed registry 依存**になります。これは「不用意な移動でラベルが消える」問題に対し、今回の候補群で最も正面から効く設計です。 35

ただし、NBAccess / SourceVault も万能ではありません。公開 README には、**すべての永続化が PrivateVault 配下に集約されること、外部 LLM へは sanitized snippet のみを渡すこと、検索結果や live view にも release context gate を二重適用**することが明記されていますが、一方で **Cane 系の一部安全基盤**

は **observe-only / shadow** が既定であり、所有者が enforcement を有効化しない限り block しない箇所があります。したがって、「設計上の材料」は最も豊富でも、**デフォルトで完全な mandatory enforcement** になっているわけではありません。ここは導入時の設定と運用が重要です。 ³⁶


ClawXRouter / EdgeClaw が強いのは、ラベルを永続的に持たせるからではなく、**途中経路をすべて再検査** するからです。公開資料では、cloud model が **MEMORY-FULL.md** や **sessions/full/** を見ないこと、そして Hook system が **file access layer** で intercept することが明記されています。さらに **before_tool_call** で file access guard、**after_tool_call** で tool result detection、**tool_result_persist** で dual-track session write、**before_message_write** で S2/S3 の置換が走るため、仮に上流で path-based な分類が漏れても、**最後の出口で落とせる** 可能性が高いです。これは content-hash 追跡ほど美しくはないものの、実運用では非常に強い防御です。 ³⁷

vLLM Semantic Router は、request が prompt になった後の出口防御としては有効です。Dell の検証資料では、PII を含む request は **backend model へ転送せず content-filtered response を返す** と説明されています。ただし同資料は、既定構成では **direct/structured PII は拾えるが contextual / obfuscated case を多く見逃す** と述べています。つまり、**path-based の事故を prompt 上で最後に止める安全弁** にはなりませんが、それ自体が **ラベル喪失を防ぐ基底設計** にはなりません。 ³⁸

PRISM / Privacy-R1 / PrivacyRestore は、ここでは本質的に「補助輪」です。PRISM は entity-level の感度と local DP、Privacy-R1 は chunk-level routing、PrivacyRestore は privacy span removal と restoration vector によって、**クラウドへ何を出すかを最適化** します。しかしこれらは、**ファイルが別フォルダへ動いた、添付経路が変わった、内部 agent message に再展開された** といった経路逸脱を追うものではありません。**ToolPrivacyBench** が示すように、ツール呼び出しでは task-private atoms が authorized tool にしか渡らないこと自体を監査対象にすべきであり、**AgentLeak** が示すように multi-agent では内部チャネルが主漏洩面になります。つまり research privacy routing は必要ですが、それだけでは足りません。 ³⁹

この意味で、「ファイル移動やラベル喪失」に対する耐性を実務上の順序で並べると、**NBAccess / SourceVault** が最も理論的に強く、**ClawXRouter / EdgeClaw** が最も運用で止めやすく、**vLLM Semantic Router** がシンク側の補助、その他は**送信前匿名化や privacy-utility tradeoff 最適化** として位置づけるのが妥当です。**SecureLLM** は file-level ではなく **silos-level credential wall** に強いので、組織横断データ共有を抑える用途には価値がありますが、ファイル移動事故の直接対策ではありません。 ⁴⁰

以下は、この問題への推奨情報フローです。ポイントは、**ラベルを「保持」する層と、送信直前に「再判定」する層** を必ず分けることです。これは NBAccess/SourceVault と ClawXRouter/EdgeClaw、さらに gateway DLP を組み合わせた構成の要約です。 ⁴¹



性能影響と運用コスト

コスト最適化を最も前面に出しているのは **ClawXRouter / EdgeClaw / vLLM Semantic Router** です。ClawXRouter は PinchBench 上で **5-model mix** が **All Sonnet 4.6** より **58% 低コスト**かつ **6.3% 高スコア**だと報告しています。EdgeClaw 側でも cost-saving router と tool governance によるトークン節約をうたい、**context trimming + interception + notes append** で **30 ラウンド中 85% token saving** としています。これは「高価な frontier model を常用しない」という面で、ハイブリッド運用の即効薬です。 ²⁶

vLLM Semantic Router は、オープンな serving stack での費用対効果が明確です。論文では MMLU-Pro で **accuracy 58.57%、latency 13.09s、tokens 887.5** として、direct vLLM の **48.33%、24.76s、1,722.1 tokens** に比べて **accuracy +10.24pp、latency -47.1%、tokens -48.5%** を報告しています。Red Hat の解説はさらに、インテリジェント routing が **90% 超の token cost reduction** をもたらし得ると述べています。これは **生成品質を落とさずに cloud/local を振り分けたい** 場合の有力な基盤です。 ⁴²

PRISM は研究系の中では、レイテンシとエネルギーまで公開している点が実務的です。PRISM の abstract は、**energy consumption and latency を Uniform / Selective LDP の 40–50% にしつつ strong privacy constraints 下でも quality を保つ**と述べています。つまり、単純な「全部 local DP をかけて送る」方式より、**感度に応じて mode を切り替える**ほうが、クラウド API コール数だけでなく edge 計算も含めた総コストを下げやすいことを示唆しています。 ¹⁸

PrivacyRestore は DP 系の中では比較的現実的です。ACL 論文では、client-side の privacy span identification と meta-vector construction による **slight latency** はあるものの、推論スループットはデータセット別に **64% / 78% / 77%**、全体として **65–80%** の元 throughput を維持したとしています。また privacy budget が protected text length に対して **線形に伸びない**点は、実運用上の大きな強みです。ただし client / server の双方に追加ロジックが入り、既存 SaaS API にそのまま差し込めるかは実装依存です。 ⁴³

Privacy-R1 は quality-leakage frontier の改善は明確ですが、運用コストはまだ読みづらいです。公開実験は **GPT-4o-mini** を **remote model**、**Llama** 系や **Mistral/Qwen** を **local model** とした品質・漏洩比較が中心で、system-level latency や total API spend の評価は主題ではありません。アーキテクチャ上は **semantic chunking + MiniLM embedding + 2-layer Transformer policy agent + local/remote composition** が追加されるため、**学習済み policy を持つ adaptive router** としては有望でも、今すぐ production budget calculator に載せやすい段階ではありません。 44

AgentStealth / SEAL / EvidenceBot は、別の意味で安いです。これらは**ローカル推論へ寄せることで API 課金そのものを減らす**タイプです。SEAL は inference 時に外部モデルへ依存しない匿名化 SLM を目指しており、AgentStealth は edge devices への直接配備をうたいます。EvidenceBot も local RAG で commercial platform の制約を回避する設計です。ただし、これらは**GPU/CPU を自前で持つ前提の CapEx/運用負荷**へコストを移すため、単純に「無料」ではありません。公開資料でも serving throughput や大規模 concurrent load の数字は限定的です。 45

運用負荷の観点では、**NBAccess / SourceVault** は最もガバナンス志向ですが、Wolfram/Mathematica 前提であり、既存 Python/TypeScript ベースの agent stack へ直に入れるには高コストです。対して **ClawXRouter / EdgeClaw** は OpenClaw エコシステムなら導入障壁が比較的低く、**dashboard・audit.jsonl・sandbox** まで同梱されています。**vLLM Semantic Router** は cloud-native / Envoy / classifier tuning を要するため MLOps 体制が必要です。研究プロトタイプ群は、再現コードがあっても production hardening、監査ログ、鍵管理、SLA までは通常自前になります。 46

推奨アーキテクチャと導入計画

最も現実的な推奨は、**NBAccess + SourceVault** をデータ境界の正本にし、**ClawXRouter** の **hook-based routing / redaction / dual-track memory** を取り込み、クラウド出口に **vLLM Semantic Router** 風の **gateway recheck** を置く構成です。理由は明確で、**データにラベルを付ける層、オーケストレータ内部の tool / memory / agent 間チャンネルを載く層、外部 API へ出る直前を止める層**を分離できるからです。どれか一層だけでは、Path ベースの事故、内部チャンネル漏洩、prompt 化後の見落としのいずれかが残ります。 47

この拡張案では、SourceVault 的な **source / snapshot / bundle** 管理を一般化し、各ファイル・添付・RAG chunk に **LogicalSourceId** を振ります。実装としては、**SHA-256 content hash** を基底に、元の source URI、ingest 時刻、生成物の lineage、current lifecycle status を registry に保持し、プロンプトや tool arguments に**実体そのものではなく label-aware handle**を流します。NBAccess がすでに持つ **ObjectSpec / PrivacyLevel / NBPrivacyLevelToRoutes** は、この registry の policy adapter として非常に相性が良いです。加えて SourceVault の **immutable snapshot / append-only event log / revocation set** を使えば、「古い引用が残る」「stale source を元に再送する」事故も減らせます。 48

次に、ClawXRouter/EdgeClaw 的な発想で、**オーケストレータの全 internal channel** をフックします。最低限必要なのは、**before_prompt_build、before_tool_call、after_tool_call、before_message_write、memory_persist** の五か所です。ここで、(a) ラベル付き handle を実体へ解決する前の access check、(b) tool schema に対する purpose-bound minimization、(c) tool result の再分類、(d) cloud history と local history の分離、(e) tamper-evident audit log を行います。これは **AgentLeak** が示した internal channel 漏洩、そして **ToolPrivacyBench** が示した unnecessary private information の中間 tool call 漏洩へ直接効きます。 49

最後に、クラウド出口では **gateway 再検査** を必須にすべきです。これには vLLM Semantic Router のような Envoy/ext_proc 型が向いています。理由は、アプリ側の route 判定や redact 処理は**必ずバグ**るからです。ClawXRouter 型の route 判定で「S2 にしたつもり」の内容が、マージや intermediate prompt build で再混入することは十分起こります。そこで gateway 側で **PII / jailbreak / enterprise-specific patterns** をもう一

度見て、違反なら block する。vLLM 資料でも、既定の PII detector は contextual case に弱いとされるため、ここは**業務ドメイン固有の detector チューニング**が前提になりますが、それでも「最後の門番」を持つ価値は大きいです。 50

長期的には、**OS 統合**と **confidential inference** を併用したいところです。今回の候補群で OS 側へ最も踏み込んでいるのは **ClawXSandbox** ですが、これは主に agent execution の隔離です。もし本当にクラウド推論を使うなら、秘密文書や retrieval 結果を扱う場面では、**TEE による attestation と key release**を持つ confidential inference が有力です。Anthropic の confidential inference whitepaper は、AI inference における TEE、attestation、restricted operator access、confidential data / confidential model の二側面を整理しており、NVIDIA も attestation と key broker を含む confidential computing を AI inference 向けに説明しています。極秘ワークロードでは、MPC 系の **PUMA** のような技術も将来的選択肢ですが、現状のレイテンシは一般的な interactive orchestration には重すぎます。 51

導入チェックリストと実行プラン

実務向けの導入チェックリストは、まず **データ分類の正本をフォルダではなく object registry に置くこと**から始まります。具体的には、**source ingest 時に source ID と content hash を必ず採番する、PrivacyLevel が未設定のものは fail-safe で local-only にする、cloud へ出してよいのは CloudPublishable 相当の明示 declassify 済み object だけにする、tool schema ごとに authorized fields を定義する、tool result も再分類する、audit log を append-only にする**、の六点です。NBAccess / SourceVault はこのうち source/snapshot/provenance と fail-safe 側の材料を多く持っており、ClawXRouter/EdgeClaw は routing と hook と audit の材料を持っています。 52

テスト計画は、**最終出力だけを見る評価**から必ず卒業すべきです。最低限、**ConfAlde** で contextual privacy reasoning、**PrivacyLens** で user-to-agent / agent action の norm awareness、**ToolPrivacyBench** で tool trajectory の purpose-bound disclosure、**AgentLeak** で multi-agent internal channel を評価してください。ConfAlde は強いモデルでも context 不適切な private disclosure をしうことを示し、PrivacyLens は privacy-sensitive seeds から実際の action trajectory まで評価します。ToolPrivacyBench は 2,150 ケースで authorized tool のみへの disclosure を監査し、AgentLeak は output-only audit が多数の違反を見逃すことを示しています。これらを CI に入れると、「ルート判定は正しいが中間 tool call で漏れていた」という事故を検出できます。 53

IBM AI Privacy Toolkit は、本番ルーティング評価というより、**周辺の匿名化・リスクアセスメント**に使うのが適切です。学習データや synthetic data を匿名化し、モデルやデータセットの privacy/compliance を評価する用途では価値がありますが、**NBAccess や ClawXRouter の代わり**にはなりません。むしろ、運用前の学習・微調整・評価パイプラインに置き、ランタイムには **Contextual Privacy Toolkit** のような overdisclosure reformulation 層を足す、という使い分けが現実的です。 54

優先度付きの実行プランは、次の三段階が妥当です。**短期**では、既存オーケストレータに **ClawXRouter 型の hook 再検査**を入れ、cloud history と local history を分け、tool arguments の最小化と audit を始めるべきです。これは最も早く漏洩面積を減らします。**中期**では、添付・ファイル・RAG source を **NBAccess + SourceVault 型の LogicalSourceId / content-hash / immutable snapshot / provenance**へ移し、route 判断を path ではなく object registry へ寄せるべきです。**長期**では、vLLM Semantic Router 風の gateway を強化し、必要ワークロードには **TEE-based confidential inference** を組み込む。最上位機密だけ MPC/FHE 系へ逃がす、という分離統治が現実的です。 55

総括すると、**ファイル移動やラベル喪失に最も強い「種」**は NBAccess / SourceVault、日々のエージェント実行で実際に漏洩を止めやすい**「運用防御」**は ClawXRouter / EdgeClaw、**クラウド出口の堅い門番**は **vLLM Semantic Router** です。**PRISM / Privacy-R1 / PrivacyRestore** はその内側で privacy-utility を改善する戦術、**AgentStealth / SEAL / EvidenceBot / SecureLLM** はクラウド露出自体を減らす戦術、

ConfAlde / PrivacyLens / ToolPrivacyBench / AgentLeak / IBM APT は妥当性確認の戦術として位置づけるのが最も整合的です。単独採用より、**data-bound label + hook reinspection + gateway reinspection** の三重防御に寄せることを強く推奨します。 56

1 36 46 GitHub - transreal/SourceVault: External source / notebook vault for Mathematica (PrivateVault + CloudMirror, ingest/extract/claim/bundle pipeline) · GitHub
<https://github.com/transreal/SourceVault>

2 5 6 8 9 15 25 35 40 41 47 48 52 56 GitHub - transreal/NBAccess · GitHub
<https://github.com/transreal/NBAccess>

3 12 18 39 PRISM: Privacy-Aware Routing for Adaptive Cloud-Edge LLM Inference via Semantic Sketch Collaboration
<https://arxiv.org/pdf/2511.22788>

4 10 16 26 GitHub - OpenBMB/ClawXRouter · GitHub
<https://github.com/OpenBMB/ClawXRouter>

7 [2409.00138] PrivacyLens: Evaluating Privacy Norm Awareness of Language Models in Action
<https://arxiv.org/abs/2409.00138>

11 17 GitHub - vllm-project/semantic-router: Intelligent Mixture-of-Models Router for Efficient Heterogeneous LLMs Inference · GitHub
<https://github.com/vllm-project/semantic-router>

13 21 32 33 45 [2506.22508] AgentStealth: Reinforcing Large Language Model for Anonymizing User-generated Text
<https://arxiv.org/abs/2506.22508>

14 24 53 [2310.17884] Can LLMs Keep a Secret? Testing Privacy Implications of Language Models via Contextual Integrity Theory
<https://arxiv.org/abs/2310.17884>

19 29 44 aclanthology.org
<https://aclanthology.org/2026.acl-long.2130.pdf>

20 30 31 43 aclanthology.org
<https://aclanthology.org/2025.acl-long.532.pdf>

22 EvidenceBot: A Privacy-Preserving, Customizable RAG-Based Tool for Enhancing Large Language Model Interactions
<https://par.nsf.gov/servlets/purl/10639617>

23 34 aclanthology.org
<https://aclanthology.org/2026.privatenlp-main.3.pdf>

27 37 49 55 GitHub - OpenBMB/EdgeClaw: EdgeClaw: Edge-Cloud Collaborative Personal AI Assistant based on OpenClaw · GitHub
<https://github.com/OpenBMB/EdgeClaw>

28 42 When to Reason: Semantic Router for vLLM
<https://arxiv.org/html/2510.08731v1>

38 50 PII (Personally Identifiable Information) Detection | Open-Source LLM Inferencing at Scale: vLLM Production Stack on Dell AI Factory | Dell Technologies Info Hub

<https://infohub.delltechnologies.com/ja-jp/l/open-source-llm-inferencing-at-scale-vllm-production-stack-on-dell-ai-factory/pii-personally-identifiable-information-detection/>

51 [External - font change] Confidential inference systems: Design principles and security risks - June 2025

https://assets.anthropic.com/m/c52125297b85a42/original/Confidential_Inference_Paper.pdf

54 GitHub - IBM/ai-privacy-toolkit: A toolkit for tools and techniques related to the privacy and compliance of AI models. · GitHub

<https://github.com/IBM/ai-privacy-toolkit>